1. Tổng quan và kết quả

Atlas Insight phân tích quốc gia theo năm và trả 3 kết quả: tuổi thọ dự đoán, nhãn tuổi thọ ≥70 năm và cụm hồ sơ. Một dòng là một quốc gia tại một năm.

Dữ liệu	Mô hình
1.704 dòng AI, 142 nước, 1952–2007	PCA 7 PC, giữ 91.25% phương sai
3.104 dòng đa nguồn; 1.704 khóa nước–năm	K=2; Silhouette=0.2879
Scrapy tải 12.768 dòng, 8 thuộc tính	Hồi quy: LinearRegression, RMSE 6.171 năm
375 ô mô phỏng thiếu ở nhánh AI	Phân loại: LogisticRegression, F1 macro 0.845

Đã sửa: crawler thật, missingno, xử lý ngoại lai, imputation trong train, validation riêng, model cùng phiên bản, UI truy vấn vector thật và Docker đa container.

Đã kiểm chứng: 8 test, UI/Chroma HTTP và truy vấn sau restart DB. Docker Engine chưa có trong môi trường sửa; chạy Compose hoặc chờ GitHub Actions xanh trước khi xác nhận Docker thành công.

Người	Báo cáo khoảng 4–5 phút
1	Nguồn, Scrapy, concat và merge
2	Lưu trữ, làm sạch, insight EDA
3	Feature, chia tập, 6 thuật toán và metrics
4	UI, Docker, demo và kết luận

Giữ 5 tác giả của báo cáo gốc; nhóm tự chọn 4 người đứng báo cáo. Không cần đọc lại toàn bộ code vẽ giao diện.

2. Thu thập và tích hợp dữ liệu

00_crawl_worldbank.py: Scrapy gọi API World Bank SP.DYN.LE00.IN, phân trang, retry và tôn trọng robots.txt. Chỉ ghi dữ liệu sau khi tải đủ trang và đạt ≥300 dòng. Có timestamp, URL và SHA256 trong crawl_audit.json.

Thao tác	Kết quả / lý do
01: chuẩn hóa Gapminder	1.704 dòng; sửa ISO Triều Tiên thành PRK; tạo record_id
09: lọc World Bank	1.400 dòng tương ứng nước/năm trong Gapminder
10: inner join	1.394 cặp đủ tuổi thọ; chênh lệch TB 1,795 năm
11: concat	1.704 + 1.400 = 3.104 dòng; giữ data_source
12: left merge, many_to_one	Bổ sung GDP/dân số và sim_*; giữ tất cả dòng nguồn
13–14: điền và audit	6 tuổi thọ từ Gapminder có flag; 690 ô sim_* được điền

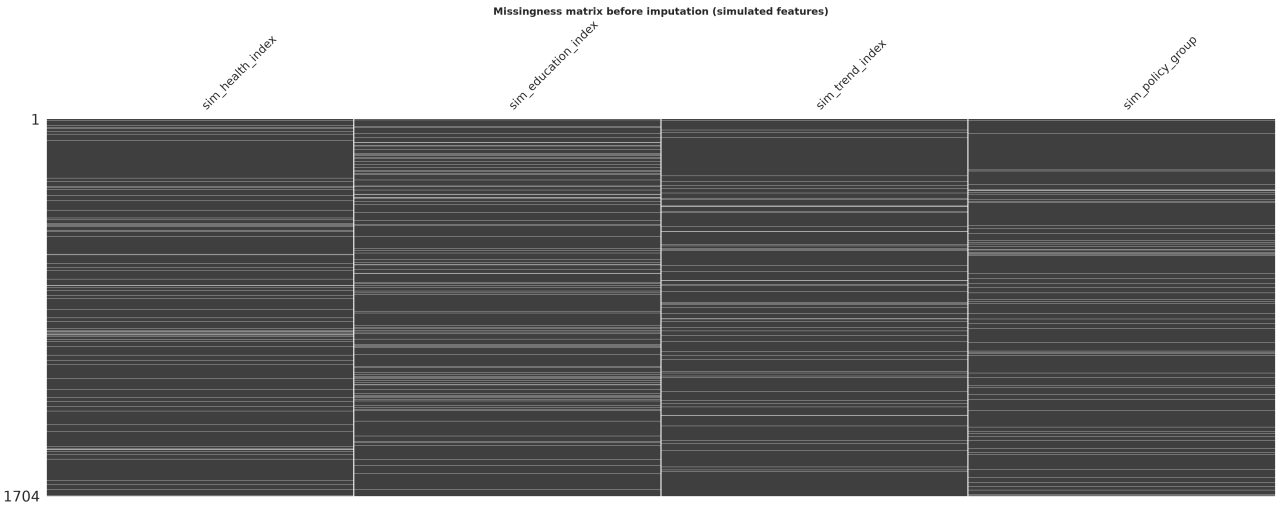
Khóa: nhánh AI dùng record_id duy nhất; nhánh nguồn dùng (data_source, iso_alpha, year). Không đưa thẳng 3.104 dòng vào ML vì trùng đơn vị nước–năm.

sim_*: sinh từ GDP, năm và nhiễu; chỉ dùng thực hành. GDP/dân số trên dòng World Bank vẫn lấy từ Gapminder, có economic_data_source để truy vết.

Khi cô hỏi: concat nối hàng; merge thêm thông tin bằng khóa. Inner dùng cho đối chiếu cặp chung; left dùng khi phải bảo toàn bảng nguồn.

3. Làm sạch và EDA

02 xử lý dữ liệu để mô tả: median health/education theo châu lục, ffill/bfill trend trong từng nước, Unknown cho policy. Không xóa hàng. Missingno hiển thị cấu trúc thiếu; so sánh mean, median, std trước/sau.



ML dùng quy trình riêng: 03 đọc master_sparse; FeatureCleaner chỉ học median và giới hạn IQR từ train. Transform test chỉ dùng thống kê đã học, không bfill theo các dòng test.

Phát hiện	Ảnh hưởng đến ML
GDP/dân số có đuôi dài	log1p rồi giới hạn IQR cho 2 feature này; không cắt target tuổi thọ
Spearman GDP–tuổi thọ ≈0,8265	Giữ GDP làm feature; tương quan không chứng minh nhân quả
Lớp/vùng không cân bằng	Chia theo nước, stratify châu lục ở outer split; class_weight balanced
Một nước có 12 năm	Giữ nước tách biệt giữa fit, validation và test

4. Mô hình và đánh giá

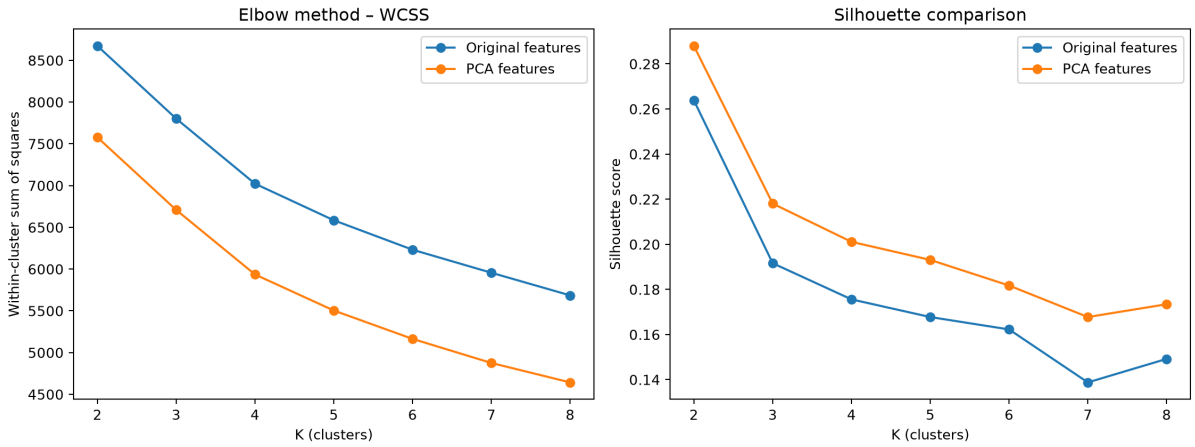
X gồm 6 cột số và 2 danh mục. log_population/log_gdp giảm lệch; StandardScaler chuẩn hóa số; OneHotEncoder mã hóa continent/policy. Không đưa tuổi thọ, target hay Cluster_Label vào X.

Supervised: 90 nước fit, 23 validation, 29 test. Chọn winner theo RMSE/F1 macro trên validation; refit 113 nước rồi đánh giá test 348 dòng. PCA chỉ dùng cho clustering.

Thuật toán	MSE	RMSE	R^2
LinearRegression	38.077	6.171	0.778
DecisionTreeRegressor	45.163	6.720	0.737

Thuật toán	Accuracy	F1 macro
LogisticRegression	87.07%	0.845
DecisionTreeClassifier	85.06%	0.820

PCA/K-Means: 7 PC giữ 91.25%; thử K=2..8 trên dữ liệu gốc và PCA. Chọn Silhouette cao nhất: K=2, 0.2879. Ánh xạ nhãn về CSV/SQLite.



RMSE nhỏ tốt hơn; R^2 không phải Accuracy. F1 macro cân bằng đóng góp 2 lớp. Silhouette còn thấp nên cụm chỉ dùng khám phá.

5. Database và giao diện

Thành phần	Code / luồng
SQLite	02 ghi/đọc master_sparse, master_clean; 03 ghi master_with_clusters
ChromaDB	04 dùng model PCA đã lưu, upsert vector 7 chiều; đọc lại DataFrame và so sánh vector
UI	Nạp 3 joblib; validate input; features → predict; trả tuổi thọ, nhãn/xác suất và cụm
Tìm tương đồng	UI gọi ChromaDB query thật; 5 hàng gần nhất kèm distance_l2
Docker	web và chroma tách container; Web gọi chroma:8000, dữ liệu vector lưu volume

start_app.py chờ DB sẵn sàng, đồng bộ vector rồi mở Gradio. UI không huấn luyện lại khi bấm nút. Không có LLM trong luồng dự đoán.

Input không hợp lệ như NaN, dân số/GDP ≤0, năm ngoài phạm vi hoặc chỉ số ngoài 0–100 được từ chối. Nếu 2 model bất đồng ở ngưỡng 70, UI hiển thị lưu ý; không ép kết quả cho giống nhau.

Chạy: docker compose up --build -d --wait
Mở: http://localhost:7860
Test: docker compose exec web python -m pytest tests -q

GitHub Actions chạy Compose, test HTTP, restart database và chụp 4 tab UI. Ảnh Docker nằm trong artifact docker-ui-evidence sau khi workflow chạy thành công; không dùng ảnh cũ để chứng minh bản mới.

6. Các file cần mở khi cô hỏi

File	Vai trò
00_crawl_worldbank.py	Thu thập World Bank thật bằng Scrapy
01_prepare_data.py	Gapminder, mô phỏng, khóa và ghép AI
02_storage_clean_eda.py	SQLite, thiếu, thống kê và 11 hình EDA
03_model_stage2.py	6 thuật toán, validation/test, metrics và lưu model
transforms.py	Imputation và IQR clipping học trong train
04_chromadb_vector.py	Nạp vector và kiểm tra đọc ngược
vector_store.py	Client local/HTTP, DataFrame, nearest query
09–14	Chuẩn hóa, đối chiếu, concat/merge và audit đa nguồn
ui/app.py; start_app.py	Giao diện, inference; khởi động an toàn
tests/; .github/workflows/verify.yml	Test dữ liệu, mô hình, live DB, UI và Docker CI
run_pipeline.py; 07; 08	Tái tạo đầu ra; tạo PDF/notebook; xuất notebook copy
05_bonus_web_crawler.py; 06_bonus_ollama_text.py	Tham khảo ngoài luồng chính, không dùng làm bằng chứng rubric

notebook dùng output hiện tại và chỉ đọc artifact khi Run All; không ghi đè model. reports/ lưu bảng kiểm toán; charts/ lưu biểu đồ; models/ là artifact nhị phân, không phải source code.

7. Phân công và kịch bản demo

Người	Mở file / lời chốt
1	00, 11, 12: “3.104 là dòng theo nguồn; chỉ 1.704 country-year duy nhất dùng ML.”
2	02, 04, charts 06/07/17: “Thiếu được xử lý theo loại biến; imputation ML chỉ học train.”
3	03, validation_benchmark, regression/classification_benchmark: “Chọn winner trên validation, báo cáo test riêng.”
4	UI, Compose, smoke_http: “3 mô hình độc lập; các dòng tương tự lấy thật từ vector DB.”

Demo 3 phút:

1. Mở UI, giữ mặc định Asia / 2002 / dân số 25 triệu / GDP 5.000 / sim 70–65–70.
2. Bấm Phân tích bằng AI; đọc 3 kết quả và bảng khoảng cách vector.
3. Mở Trực quan hóa, chỉ quan hệ GDP–tuổi thọ.
4. Mở Kết quả đánh giá, giải thích vì sao chọn winner.
5. Chỉ test/CI và kết thúc bằng giới hạn dữ liệu lịch sử.

Khuyến nghị:

- Dùng cụm để chọn hồ sơ cần nghiên cứu sâu, kiểm chứng bằng nguồn cập nhật.
- Giữ mô hình đơn giản làm baseline; ưu tiên dữ liệu thật và sai số theo vùng.
- Cảnh báo khi các mô hình bất đồng, để người dùng xem lại thay vì tự ra quyết định.

Không đọc toàn bộ báo cáo. Mỗi người giải thích input → xử lý → output và một lý do kỹ thuật trong phần mình.

8. Câu hỏi ngắn và checklist

Câu hỏi	Trả lời
Tại sao PCA 7 mà hình 2D?	7 chiều để phân cụm; 2D chỉ là phép chiếu để vẽ.
K=2 có phải target có 2 lớp?	Không. K chọn qua Silhouette, clustering không dùng target.
R^2 0,778 có phải đúng 77,8%?	Không. Đây là mức giải thích biến thiên theo sai số bình phương.
Tại sao F1 macro?	Lớp mất cân bằng; macro cho mỗi lớp trọng số ngang nhau.
Tại sao 2 model bất đồng?	Hồi quy và classifier học độc lập; UI đã báo bất đồng.
3.104 dòng có dùng train?	Không; bảng này phục vụ tích hợp và đối chiếu nguồn.
Đã chạy Docker chưa?	Đã viết cấu hình/CI; chỉ xác nhận chạy khi Compose hoặc workflow thành công.

Trước khi báo cáo: cài đúng requirements; chạy 8 test; mở UI; xác nhận CI Docker; tải ảnh docker-ui-evidence; thống nhất số liệu trong reports; tập nói 4 người.

Giới hạn: dữ liệu lịch sử 1952–2007; sim_* giả lập; nhãn 70 do nhóm chọn; chưa chứng minh nhân quả, hiệu chuẩn xác suất hay dự báo tương lai. Silhouette khoảng 0,288 cho thấy cụm tách chưa mạnh.

Nguồn: Grading Rubric.xlsx (6 mục, tổng 10 điểm); code và reports hiện tại; Gapminder/Plotly; World Bank SP.DYN.LE00.IN. Crawl được ghi ngày 2026-10-31.